

高级计量经济学

Lecture 7: Hypothesis Testing

黄嘉平

工学博士 经济学博士
深圳大学中国经济特区研究中心 讲师

办公室	粤海校区汇文楼1510
E-mail	huangjp@szu.edu.cn
Website	https://huangjp.com

假设检验的基础知识

假设检验的思维方式

The Idea of Hypothesis Testing

考虑回归模型

$$y_t = \beta + u_t, \quad u_t \sim \text{IID}(0, \sigma^2)$$

此时 OLS 估计量满足 $\hat{\beta} = \frac{1}{n} \sum_{t=1}^n y_t$, $\text{Var}[\hat{\beta}] = \frac{1}{n} \sigma^2$ 。

我们想知道总体中的 β 是否满足某种限制条件，例如

$$H_0 : \beta = \beta_0 \quad \text{vs} \quad H_1 : \beta \neq \beta_0$$

H_0 是零假设 (null hypothesis), H_1 是备择假设 (alternative hypothesis)。

我们要针对 H_0 进行检验，就是要找到一个检验统计量 (test statistic)，并使其满足：

1. 当零假设正确时，我们知道该统计量服从分布 A ；
2. 当零假设错误（即备择假设正确）时，我们知道该统计量服从分布 $B \neq A$ 。

如果零假设正确时很难获得样本中检验统计量的取值的话，我们就有理由相信零假设是错误的。当理由充分时，我们即可拒绝 (reject) 零假设，而偏向于接受 (accept) 备择假设。

统计量的分布

Distribution of Test Statistic

首先我们假定零假设 $H_0 : \beta = \beta_0$ 成立（这里的 β_0 就是总体中 β 的真实值）。同时我们假设 u_t 服从正态分布且 σ 已知。

一个常用的检验统计量是

$$z = \frac{\hat{\beta} - \beta_0}{\sqrt{\text{Var}[\hat{\beta}]}} = \frac{\sqrt{n}}{\sigma}(\hat{\beta} - \beta_0)$$

因为 $\hat{\beta}$ 非偏，则在零假设下 $E[z] = 0$ 。 z 的方差为

$$\text{Var}[z] = E[z^2] = \frac{n}{\sigma^2} E[(\hat{\beta} - \beta_0)^2] = \frac{n}{\sigma^2} \frac{\sigma^2}{n} = 1$$

如果 u_t 服从正态分布， z 也服从正态分布，所以 $z \sim N(0,1)$ 。

如果备择假设 $H_1 : \beta \neq \beta_0$ 成立，那针对任意 $\beta = \beta_1 \neq \beta_0$ ，则有 $\hat{\beta} = \beta_1 + \hat{\gamma}$ 。可知 $\hat{\gamma}$ 服从 $N(0, \sigma^2/n)$ ，因此 $z \sim N(\lambda, 1)$ ， $\lambda = \frac{\sqrt{n}}{\sigma}(\beta_1 - \beta_0)$ 。

拒绝域和接受域


Rejection and Acceptance Regions

$$H_0 : \beta = \beta_0 \Rightarrow z \sim N(0,1)$$

$$H_1 : \beta \neq \beta_0 \Rightarrow \text{对任意的 } \beta = \beta_1, z \sim N(\lambda, 1), \lambda = \frac{\sqrt{n}}{\sigma}(\beta_1 - \beta_0)$$

当 n 足够大时，则在备择假设下，大概率可以观测到 z 的取值显著不为零。如果我们确实观测到 $|z| \gg 0$ ，就可以拒绝零假设。

我们需要事先规定一个拒绝零假设的规则。通常我们设定一个拒绝域 (rejection region)，当 z 的取值在该域中时，就拒绝零假设。**检验 (test) = 检验统计量 + 拒绝规则**。拒绝域以外的区域是接受域 (acceptance region)。



检验可能出错

因为样本的随机性，所有检验都可能出现错误。

通常存在两种检验错误：

	检验结果	
	接受零假设	拒绝零假设
零假设成立	正确	Type I error
备择假设成立	Type II error	正确

检验的显著性水平（level of significance）： $\alpha = \text{Pr}(\text{type I error})$


检验的功效（power）： $\text{Pr}(\text{reject } H_0)$

当 H_0 成立时， $\text{power} = \alpha$ ；当 H_1 成立时 $\text{power} = 1 - \beta = 1 - \text{Pr}(\text{type II error})$


注意：这里的 β 不是回归系数

功效的大小受样本量的影响。当样本量固定时，往往无法同时减小两种错误的概率。因此，我们通常固定 α ，即显著性水平，然后选择 β 更小的检验。

当拒绝域是 $z > c_R$



当拒绝域是 $z < c_L$



临界值和 P 值


Critical Value and the P Value

当给出检验的显著性水平 α 时，我们可以通过确定临界值的方式给出该检验的拒绝域。

z 统计量服从标准正态分布，则双尾检验的临界值 c_α 可以通过下面的隐函数定义

$$\begin{aligned}\Phi(c_\alpha) &= 1 - \frac{\alpha}{2} \\ \Leftrightarrow c_\alpha &= \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)\end{aligned}$$

Φ 是标准正态分布的累积分布函数



当我们观测到估计值 \hat{z} 时，我们将 $2\Pr(z > |\hat{z}|)$ 定义为该检验的 P 值 (marginal/observed significance level)。 P 值是临界值为 \hat{z} 的检验所对应的显著性水平。

P 值受样本量影响。样本量 n 越大， P 值越小。因此，在大样本下，我们应当审视 5% 或 1% 常用显著性水平的合理性。

常用的概率分布

正态分布

The Normal Distribution

正态分布也称高斯分布（Gaussian distribution），由期望值 μ 和方差 σ^2 两个参数决定。

$N(\mu, \sigma^2)$ 的密度函数是

$$f(x \mid \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

如果 $x \sim N(\mu, \sigma^2)$ ，则 $z = \frac{x - \mu}{\sigma} \sim N(0, 1)$ 。

- 服从正态分布的独立变量的线性结合也服从正态分布。
(pp.130-132)

多变量正态分布

The Multivariate Normal Distribution

随机向量 $\mathbf{x} = (x_1, \dots, x_m)$ 服从期望值为 $\boldsymbol{\mu}$ ，协方差矩阵为 $\boldsymbol{\Omega}$ 的多变量正态分布可以表达为 $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Omega})$ 。其密度函数为

$$f(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Omega}) = \frac{1}{(2\pi)^{m/2} |\boldsymbol{\Omega}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Omega}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

因为 $\boldsymbol{\Omega}$ 是协方差矩阵，因此是半正定。
又因 $\boldsymbol{\Omega}$ 可逆，因此是正定矩阵。

- 如果 $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Omega})$ ，则 $\mathbf{a}^\top \mathbf{x} \sim N(\mathbf{a}^\top \boldsymbol{\mu}, \mathbf{a}^\top \boldsymbol{\Omega} \mathbf{a})$ 。
- 如果 \mathbf{x} 服从多变量正态分布，且协方差都为零（要素间相互不相关），则 x_1, \dots, x_m 相互独立。

相互独立 (mutual independence) :
 $f(x_1, x_2, \dots, x_m) = f(x_1)f(x_2)\cdots f(x_m)$

卡方分布

The Chi-squared Distribution

当随机向量 $\mathbf{z} \sim N(\mathbf{0}, \mathbf{I})$ 时，随机变量

$$y \equiv \|\mathbf{z}\|^2 = \mathbf{z}^\top \mathbf{z} = \sum_{t=1}^m z_t^2$$




Figure 4.4 Various chi-squared PDFs

服从自由度为 m 的卡方分布 (chi-squared distribution with m degrees of freedom)，写成 $y \sim \chi^2(m)$ 。

- $E[y] = \sum_{t=1}^m E[z_t^2] = \sum_{t=1}^m 1 = m$
- $\text{Var}[y] = \sum_{t=1}^m \text{Var}[z_t^2] = mE[(z_t^2 - 1)^2]$
 $= mE[z_t^4 - 2z_t^2 + 1] = m(3 - 2 + 1) = 2m$
- $y_1 \sim \chi^2(m_1), y_2 \sim \chi^2(m_2) \Rightarrow (y_1 + y_2) \sim \chi^2(m_1 + m_2)$

服从卡方分布的随机变量

定理 4.1

1. 如果长度为 m 的随机向量 $\mathbf{x} \sim N(\mathbf{0}, \mathbf{\Omega})$, 则 $\mathbf{x}^\top \mathbf{\Omega}^{-1} \mathbf{x} \sim \chi^2(m)$;
2. 如果 \mathbf{P} 是投影矩阵且 $\text{rank}(\mathbf{P}) = r$, $\mathbf{z} \sim N(\mathbf{0}, \mathbf{I})$ 是长度为 n 的随机向量, 则 $\mathbf{z}^\top \mathbf{P} \mathbf{z} \sim \chi^2(r)$ 。

证明:

1. $\mathbf{\Omega}$ 是对称正定矩阵, 因此存在非奇异矩阵 \mathbf{A} 满足 $\mathbf{\Omega} = \mathbf{A} \mathbf{A}^\top$ (Section 3.4)。此时考虑 $\mathbf{z} = \mathbf{A}^{-1} \mathbf{x}$: $E[\mathbf{z}] = E[\mathbf{A}^{-1} \mathbf{x}] = \mathbf{A}^{-1} E[\mathbf{x}] = \mathbf{0}$, 且

$$\begin{aligned} \text{Var}[\mathbf{z}] &= \text{Var}[\mathbf{A}^{-1} \mathbf{x}] = E[\mathbf{A}^{-1} \mathbf{x} \mathbf{x}^\top (\mathbf{A}^\top)^{-1}] \\ &= \mathbf{A}^{-1} E[\mathbf{x} \mathbf{x}^\top] (\mathbf{A}^\top)^{-1} = \mathbf{A}^{-1} \mathbf{A} \mathbf{A}^\top (\mathbf{A}^\top)^{-1} = \mathbf{I}_m \end{aligned}$$

因此 $\mathbf{z} \sim N(\mathbf{0}, \mathbf{I})$ 。而 $\mathbf{x}^\top \mathbf{\Omega}^{-1} \mathbf{x} = \mathbf{x}^\top (\mathbf{A}^\top)^{-1} \mathbf{A}^{-1} \mathbf{x} = \mathbf{z}^\top \mathbf{z}$, 所以 $\mathbf{x}^\top \mathbf{\Omega}^{-1} \mathbf{x} \sim \chi^2(m)$ 。

2. 假设 \mathbf{P} 投影到 $n \times r$ 矩阵 \mathbf{Z} 的列空间, 因此 $\mathbf{P} = \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top$,

$$\mathbf{z}^\top \mathbf{P} \mathbf{z} = \mathbf{z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{z}$$

如果令 $\mathbf{x} = \mathbf{Z}^\top \mathbf{z}$, 则 $E[\mathbf{x}] = \mathbf{0}$, $\text{Var}[\mathbf{x}] = E[\mathbf{Z}^\top \mathbf{z} \mathbf{z}^\top \mathbf{Z}] = \mathbf{Z}^\top \mathbf{Z}$, 因此 $\mathbf{x} \sim N(\mathbf{0}, \mathbf{Z}^\top \mathbf{Z})$ 。可见 $\mathbf{z}^\top \mathbf{P} \mathbf{z} = \mathbf{x}^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{x} \sim \chi^2(r)$ 。

Student's t 分布

The Student's t Distribution

如果 $z \sim N(0,1)$, $y \sim \chi^2(m)$, 且 z 和 y 相互独立, 则

$$t_m \equiv \frac{z}{\sqrt{\frac{y}{m}}}$$




Figure 4.5 PDFs of the Student's t distribution

服从自由度为 m 的 Student's t 分布, 写成 $t_m \sim t(m)$ 。

- 自由度为 m 的 t 分布存在前 $m - 1$ 个矩。因此 $t(1)$ 没有矩, $t(2)$ 仅有期望值。
- 若存在, 则 $E[t_m] = 0$, $\text{Var}[t_m] = m / (m - 2)$ 。
- 当 $m \rightarrow \infty$ 时, t 分布的方差趋近于 1, 分布自身趋近于正态分布。

F 分布

The F Distribution

当 $y_1 \sim \chi^2(m_1)$, $y_2 \sim \chi^2(m_2)$, 且 y_1 与 y_2 相互独立时,

$$F_{m_1, m_2} = \frac{y_1 / m_1}{y_2 / m_2}$$

服从自由度为 m_1 和 m_2 的 F 分布, 写成 $F_{m_1, m_2} \sim F(m_1, m_2)$ 。

- $E[F_{m_1, m_2}] = (m_2 - 1) / (m_2 - 3)$ 。
- 当 $m_2 \rightarrow \infty$ 时, $m_1 F_{m_1, m_2} \rightarrow y_1 \sim \chi^2(m_1)$ 。
- 由 t 分布的定义可知, 当 $x \sim t(m_2)$ 时, $x^2 \sim F(1, m_2)$ 。

古典正态模型下的精确检验

精确检验与古典正态模型

Exact Tests and the Classical Normal Linear Model

当检验统计量在 H_0 下的分布为已知时，该检验被称为精确检验 (exact test) 。

假设古典正态线性模型：

$$y = X\beta + u, \quad u \sim N(\mathbf{0}, \sigma^2 I)$$

其中 u 独立于 X (X 固定或在 y 之前生成) 。

“古典”一般指 X 为固定变量或 X 与 u 独立，在此假设下我们只需要考虑普通的期望值。“正态”指 u 服从正态分布。只有在针对 β 进行假设检验时才需要关于分布的完整信息。

单一约束的检验

Tests for a Single Restriction

首先我们考虑针对单个系数的假设检验。我们可以把系数向量写成 $\boldsymbol{\beta} = [\boldsymbol{\beta}_1^\top, \beta_2]^\top$ ，并针对 $H_0 : \beta_2 = 0$ 进行检验。

这里的 $\beta_2 = 0$ 可以看作系数的线性约束条件，而零假设和备择假设分别是在有约束和没有约束下的回归。

原回归模型可以写成

$$y = X_1 \boldsymbol{\beta}_1 + x_2 \beta_2 + u, \quad u \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$$

X_1 是 $n \times (k-1)$ 矩阵， x_2 是 $n \times 1$ 向量， $X = [X_1, x_2]$ 。

根据 FWL 定理， $\hat{\beta}_2$ 和 \hat{u} 可以从下面的短模型获得

$$\mathbf{M}_1 y = \mathbf{M}_1 x_2 \beta_2 + v, \quad \mathbf{M}_1 = \mathbf{I} - X_1 (X_1^\top X_1)^{-1} X_1^\top$$

此时可得
$$\hat{\beta}_2 = \frac{x_2^\top \mathbf{M}_1 y}{x_2^\top \mathbf{M}_1 x_2}, \quad \text{Var}[\hat{\beta}_2] = \frac{\sigma^2}{x_2^\top \mathbf{M}_1 x_2}$$

单一约束的检验: σ^2 已知

当 σ^2 已知时, 我们可以用下面的统计量检验 $H_0 : \beta_2 = 0$

$$z_{\beta_2} \equiv \frac{\hat{\beta}_2 - 0}{\sqrt{\text{Var}[\hat{\beta}_2]}} = \frac{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{y}}{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2} \cdot \frac{\sqrt{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2}}{\sigma} = \frac{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{y}}{\sigma \sqrt{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2}}$$

当 $H_0 : \beta_2 = 0$ 成立时, $\mathbf{M}_1 \mathbf{y} = \mathbf{M}_1 \mathbf{X}_1 \boldsymbol{\beta}_1 + \mathbf{M}_1 \mathbf{u} = \mathbf{M}_1 \mathbf{u}$, 因此

$$z_{\beta_2} = \frac{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{u}}{\sigma \sqrt{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2}}$$

z_{β_2} 是 u_1, \dots, u_n 的线性结合, 因此服从正态分布。 $E[z_{\beta_2}] = 0$,

$$\text{Var}[z_{\beta_2}] = \frac{E[\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{u} \mathbf{u}^\top \mathbf{M}_1 \mathbf{x}_2]}{\sigma^2 \mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2} = \frac{\mathbf{x}_2^\top \mathbf{M}_1 E[\mathbf{u} \mathbf{u}^\top] \mathbf{M}_1 \mathbf{x}_2}{\sigma^2 \mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2} = \frac{\sigma^2 \mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2}{\sigma^2 \mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2} = 1$$

所以 $z_{\beta_2} \sim N(0,1)$ 。

单一约束的检验: σ^2 未知

当 σ^2 未知时, 我们可以用回归标准误 s 替代 σ 。因为 $s^2 = \frac{1}{n-k} \sum_{t=1}^n \hat{u}_t^2 = \frac{\mathbf{y}^\top \mathbf{M}_X \mathbf{y}}{n-k}$, 我们可以定义下面的统计量

$$t_{\beta_2} \equiv \frac{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{y}}{s \sqrt{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2}} = \sqrt{\frac{n-k}{\mathbf{y}^\top \mathbf{M}_X \mathbf{y}}} \cdot \frac{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{y}}{\sqrt{\mathbf{x}_2^\top \mathbf{M}_1 \mathbf{x}_2}} = \frac{z_{\beta_2}}{\sqrt{\frac{\mathbf{y}^\top \mathbf{M}_X \mathbf{y}}{(n-k)\sigma^2}}}$$

已知 $z_{\beta_2} \sim N(0,1)$, 如果我们能证明 $\mathbf{y}^\top \mathbf{M}_X \mathbf{y} / \sigma^2 \sim \chi^2(n-k)$, 且 z_{β_2} 和 $\mathbf{y}^\top \mathbf{M}_X \mathbf{y} / \sigma^2$ 独立, 即可得到 $t_{\beta_2} \sim t(n-k)$ 。

$\mathbf{y}^\top \mathbf{M}_X \mathbf{y} / \sigma^2 \sim \chi^2(n-k)$: 因为 \mathbf{M}_X 是投影到 $\mathcal{S}^\perp(X)$ 的投影矩阵, 所以

$$\frac{\mathbf{y}^\top \mathbf{M}_X \mathbf{y}}{\sigma^2} = \frac{\mathbf{u}^\top \mathbf{M}_X \mathbf{u}}{\sigma^2} = \boldsymbol{\varepsilon}^\top \mathbf{M}_X \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} = \mathbf{u} / \sigma \sim N(\mathbf{0}, \mathbf{I})$$

$\dim(\mathcal{S}^\perp(X)) = n-k \Rightarrow \text{rank}(\mathbf{M}_X) = n-k$, 因此 $\mathbf{y}^\top \mathbf{M}_X \mathbf{y} / \sigma^2 \sim \chi^2(n-k)$ 。

单一约束的检验: σ^2 未知

z_{β_2} 和 $y^\top M_X y / \sigma^2$ 独立: 两个变量中随机要素全都来自 u 。 $y^\top M_X y / \sigma^2$ 只通过 $M_X u$ 受 u 的影响, 而由

$$x_2^\top M_1 u = x_2^\top P_X M_1 u = x_2^\top (P_X - P_X P_1) u = x_2^\top M_1 P_X u$$

$P_X P_1 = P_1 P_X$

可知 z_{β_2} 只通过 $P_X u$ 受 u 的影响。

$M_X u$ 与 $P_X u$ 的期望值都为 $\mathbf{0}$, 因此它们的协方差是

$$E[M_X u u^\top P_X] = M_X E[u u^\top] P_X = \sigma^2 M_X P_X = \mathbf{0}$$

$P_X M_X = \mathbf{0}$

因此 $M_X u$ 与 $P_X u$ 不相关。因为 $M_X u$ 与 $P_X u$ 都服从正态分布, 所以 $M_X u$ 独立于 $P_X u$, 所以 $y^\top M_X y / \sigma^2$ 独立于 z_{β_2} 。

综上, 我们可得 $t_{\beta_2} \sim t(n - k)$ 。

多重约束的联合检验

Joint Tests for Multiple Restrictions

当存在 r 个线性约束条件时 ($r \leq k$)，我们可以将其写成 $H_0 : \beta_2 = \mathbf{0}$ 。此时，在不同的假设下我们可以得到下面的回归模型：

$$H_0 : y = X_1\beta_1 + u, \quad u \sim N(\mathbf{0}, \sigma^2 I)$$

$$H_1 : y = X_1\beta_1 + X_2\beta_2 + u, \quad u \sim N(\mathbf{0}, \sigma^2 I)$$

因为需要检验的参数大于 1，我们不能继续使用 z 检验或 t 检验，而需要找到另一个合适的检验统计量。这里我们用有约束 (restricted) 回归和无约束 (unrestricted) 回归的拟合 (fit) 结果来建立检验统计量，并用两个回归的残差平方和作为拟合的指标。

若将有约束回归的残差平方和写为 RSSR，将无约束回归的写为 USSR，我们可以定义下面的统计量

$$F_{\beta_2} \equiv \frac{(\text{RSSR} - \text{USSR})/r}{\text{USSR}/(n - k)}$$

如果 H_0 不成立，RSSR 将大于 USSR。
因此当 F_{β_2} 取值很大时，我们倾向于拒绝 H_0 。

多重约束的联合检验

Joint Tests for Multiple Restrictions

我们将要证明 $F_{\beta_2} \equiv \frac{(\text{RSSR} - \text{USSR})/r}{\text{USSR}/(n-k)}$ 在 H_0 下服从 $F(r, n-k)$ 。

$\text{RSSR} = \mathbf{y}^\top \mathbf{M}_1 \mathbf{y}$, $\text{USSR} = \mathbf{y}^\top \mathbf{M}_X \mathbf{y}$ 。根据 FWL 定理, USSR 等于短模型 $\mathbf{M}_1 \mathbf{y} = \mathbf{M}_1 \mathbf{X}_2 \boldsymbol{\beta}_2 + \mathbf{v}$ 的残差平方和

$$\hat{\mathbf{v}}^\top \hat{\mathbf{v}} = \mathbf{y}^\top \mathbf{M}_1 \mathbf{y} - \mathbf{y}^\top \mathbf{M}_1 \mathbf{X}_2 (\mathbf{X}_2^\top \mathbf{M}_1 \mathbf{X}_2)^{-1} \mathbf{X}_2^\top \mathbf{M}_1 \mathbf{y} \quad \text{勾股定理}$$

因此, $\text{RSSR} - \text{USSR} = \mathbf{y}^\top \mathbf{M}_1 \mathbf{X}_2 (\mathbf{X}_2^\top \mathbf{M}_1 \mathbf{X}_2)^{-1} \mathbf{X}_2^\top \mathbf{M}_1 \mathbf{y}$ 。一般情况下 $\mathbf{M}_X \mathbf{y} = \mathbf{M}_X \mathbf{u}$, 在 H_0 成立时 $\mathbf{M}_1 \mathbf{y} = \mathbf{M}_1 \mathbf{u}$, 则

$$F_{\beta_2} = \frac{\boldsymbol{\varepsilon}^\top \mathbf{M}_1 \mathbf{X}_2 (\mathbf{X}_2^\top \mathbf{M}_1 \mathbf{X}_2)^{-1} \mathbf{X}_2^\top \mathbf{M}_1 \boldsymbol{\varepsilon} / r}{\boldsymbol{\varepsilon}^\top \mathbf{M}_X \boldsymbol{\varepsilon} / (n-k)}, \quad \boldsymbol{\varepsilon} = \mathbf{u} / \sigma \sim N(\mathbf{0}, \mathbf{I})$$

$$\text{rank}(\mathbf{X}_2) = r$$

已知 $\boldsymbol{\varepsilon}^\top \mathbf{M}_X \boldsymbol{\varepsilon} \sim \chi^2(n-k)$, 而分子可以写成 $\boldsymbol{\varepsilon}^\top \mathbf{P}_{\mathbf{M}_1 \mathbf{X}_2} \boldsymbol{\varepsilon}$ 并服从 $\chi^2(r)$ 。又因为 \mathbf{M}_X 和 $\mathbf{P}_{\mathbf{M}_1 \mathbf{X}_2}$ 正交, 加上 \mathbf{u} 服从正态分布可得分子与分母相互独立。因此 $F_{\beta_2} \sim F(r, n-k)$ 。